



北 京 科 技 大 学

本科生毕业设计(论文)选题报告

题目： 航空发动机系统故障诊断研究

学院： 机械工程学院

专业： 机械工程及自动化

姓名： 叶墅锋

学号： 41040104

指导教师签字： _____

年 月 日

目 录

1 课题背景及研究意义	2
1.1 课题背景	2
1.2 研究意义	3
2 文献综述	5
2.1 国内外研究现状	5
2.1.1 国外研究现状	5
2.1.2 国内研究现状	6
2.2 故障诊断算法	7
2.2.1 故障检测观测器法	7
2.2.2 相关向量机法	8
2.2.3 BP 神经网络	11
2.2.4 遗传算法	15
3 研究内容、预期目标及研究方法	20
3.1 研究内容	20
3.2 预期目标	20
3.3 研究方法	20
3.3.1 BP-GA 结合算法	20
3.3.2 故障诊断仿真建模	21
4 进度安排	22
参 考 文 献	23

1 课题背景及研究意义

1.1 课题背景

经过了数百年的发展，人们在航空航天领域方面已经取得了巨大的成就，极大地促进了相关的学科新理论和新技术的产生、发展与应用。然而在今天即使科学技术高度发达，航空航天领域的重特大事故仍不断出现，而在其中不少的是由航空发动机的故障引起的飞行事故。在航空领域，飞行器的安全隐患非常严峻。2007年9月28日，一架美国航空公司MD-82飞机在飞离圣路易斯爬升到距地面1500英尺时，发生了发动机起火事故。2014年11月10日21时40分许，由珠海飞往北京的南方航空公司CZ3739航班，在起飞一个多小时后，紧急迫降广州白云机场。事故原因被证实是发动机出现机械故障。另外，今年的2月4日上午10点半左右，台湾复兴航空的一架客机由于其发动机的失效，在基隆河坠毁，致40人遇难。这一次次航空事故无时无刻不刺激人们敏感的神经，也给人们在航空发动机的状态监控和故障诊断方面的研究敲响了警钟。

此外，从安全方面来讲，航空发动机的结构日益趋于复杂，发动机的部件出现故障的几率也由此直接增大，同时在发动机控制系统方面，也由传统的机械液压式控制系统发展到现在的全权限数字电子控制（FADEC）^[1]，一方面提高了发动机系统的控制精度，另一方面也对发动机系统的维护提出了更高的要求。

在经济方面^[2]，由于发动机在飞行中不容有失，因此不论是民航还是军事飞行，发动机都必须进行全面的特殊维护，这种维护在发动机运行成本上占有很大的比重。

虽然航空发动机状态监视和故障诊断技术是到了20世纪70年代初才诞生于英国，但由于其不仅能够有效准确地进行故障预测和识别，显著地提高发动机运行的可靠性，而且能够节省巨额的维修费用，为社会带来了明显的经济、军事和社会效益，航空发动机状态监视和故障诊断技术越来越受到航空领域的重视。而随着科学技术近20年来的飞速发展，尤其是计算机和电子技术的迅速普及和发展，航空发动机状态监视和故障诊断技术已日趋成熟，逐步发展为一门较为完整的新兴综合工程学科。

航空动力技术在新世纪将出现革命性的变化。一些新技术的应用和新概念动力的出现，将使人类进入经济、安全、快速、便捷的超高声速及大气层-外层空间自由往返航

行时代。面向21世纪的新型发动机主要有: 超燃冲压发动机 (scramjet)、组合循环发动机 (CCE)、高超声速发动机、脉冲爆震发动机 (PDE)、多全电 (More Electric) 发动机、超微型燃气涡轮发动机 (Micro Gas Turbine Engine)、新能源航空发动机。^[3] 由此可见, 航空发动机状态监视和故障诊断技术具有非常广阔的发展前景。在这种背景下, 开展故障检测和建模技术的研究工作是十分必要的。

1.2 研究意义

如今飞机严峻的安全隐患和飞行事故导致的重大损失使得航空发动机健康管理理论及相关算法的研究不断受到重视。由于飞机动力系统一旦出现故障便可能会引起重大安全事故, 这就需要对航空发动机进行状态监测和故障诊断, 以评估飞机性能, 确保安全。

因此, 对发动机的状态参数进行监视评估, 以此来实现发动机的维护管理和预测, 并准确判断发动机的运行状态, 为故障的诊断和排除提供充分的时间和判断的依据, 对此, 有效的发动机状态监视, 对于实施其视情维修决策具有重要意义。此外, 商业航空的经验显示, 近 95% 的飞机的生命周期成本是由于维护活动^[4], 同样, 美国政府记录历史表明, 飞行器运行和支持的成本可能超过最初的购买价格十倍。

航空发动机状态监视和故障诊断技术研究的意义在于能显著提高发动机运行的可靠性, 确保飞行的安全性, 减小发动机的维修周期, 简化维护步骤, 并可降低维修成本, 减少备件, 还能为实现维修策略从经验型的定期维修向更科学的视情维修提供重要的基础。有效而准确地对航空发动机故障进行定位及评定故障的严重程度, 有利于确保飞行的安全性以及缩短飞行器的停飞时间, 并减少其投入维修的人力物力; 同时, 它又为航空发动机的视情维修提供了必要的前提。

航空发动机系统的发展对于国民经济的发展和国防事业的进步有着极其重要的意义^[5]。随着对发动机的安全性和维修性的要求越来越高, 各种类型的飞行器都提出了状态监视和故障诊断的技术需求。对此, 近年来开展了很多对发动机状态监视和故障诊断方法的研究。我们需要建立一种实用的发动机故障诊断及测试方法, 通过性能和功能参数对发动机进行状态测试, 有效地对发动机的故障进行查找和定位, 从而提高航空发动机可靠性和寿命, 降低发动机使用成本。

本次毕业设计旨在通过研究航空发动机系统状态参数，设计关于发动机故障诊断的算法，并用算法进行故障诊断仿真建模，测试一些算法的科学性与实用性。这是对算法研究一次有益的尝试。

2 文献综述

2.1 国内外研究现状

2.1.1 国外研究现状

航空发动机状态监视与故障诊断技术自上世纪 70 年代以来得到了很大的发展^[6],期间国外的各种状态监视与故障诊断系统都得到发展和应用,代表性的有:美国普惠(P&W)公司的 ECMIII 系统、通用(GE)公司的 ADEPT 系统及 GEM 系统、罗·罗(Rolls-Royce)公司的 COMPASS 系统,还有 AIDS 飞行数据综合系统、ACMS 飞行状态监视系统等。

从 80 年代中期开始,美国就围绕航空发动机传感器的故障检测、隔离、重构的算法进行了深入的研究,其中 NASA Lewis 研究中心的 ADIA(Advanced DIA)计划具体地总结了当时各种适用的算法,并在 F100 发动机上成功地进行了验证^[7]。

20 世纪 90 年代初,美国国防部(DOD)和美国国家航空航天局(NASA)联合推动实施了综合高性能涡轮发动机技术(IHPTET, Integrated High Performance Turbine Engine)计划^[8],自 1988 年以来,该计划提出了通过建立健全航空发动机性能监视与故障诊断系统,将发动机生产和维护费用降低 35%~60%的目标,大大提高航空推进系统能力。与 IHPTET 计划一样,美国空军研究实验室(AFRL)通用经济可承受的先进涡轮发动机(VAATE, Versatile Affordable Advanced Turbine Engines)计划仍由美国国防部主持,NASA、能源部和 6 家发动机制造商参与。其投资水平也与 IHPTET 计划的相当,每年 3 亿多美元,与 IHPTET 计划相比,VAATE 计划发展的重点是经济可承受性,该计划将为美国空军发展的一系列发动机提供技术,并负责更大范围的发展项目。这将极大地提高发动机使用的效率,降低维护费用并提供具有前沿性的先进推进系统的健康管理技术。可见,人们对航空发动机故障诊断的研究越来越复杂化,控制系统传感器的故障诊断也不再是仅仅是在只发生传感器故障情况下进行诊断。

近十年来,随着发动机状态监视和故障诊断技术的发展,发动机健康管理系统(EHM)^[9,10]这一全新的概念被提了出来。EHM 系统设计包含了传感器、数据管理、故障诊断算法和预测技术、发动机寿命分析等多种技术,可以完成对发动机性能变化趋

势的预测、进行传感器故障诊断隔离以及对气动热力系统的实时监控和诊断、对发动机健康状况和剩余使用寿命的预测等任务。EHM 作为发动机设计的一个重要组成部分，是对发动机进行信息感知和辨识、处理再生并最终利用再生决策信息对发动机施效的一个过程，研制出可靠的发动机状态监视与故障诊断系统对于实现健全的健康管理系统有着重要的现实意义。

2.1.2 国内研究现状

与国外相比，我国航空发动机状态监控和故障诊断技术的研究还处于初级阶段，尤其是在军机方面。目前服役的国产军用飞机发动机还没有较完整的发动机状态监控与故障诊断系统。国内在航空领域的学者和专家们对航空发动机进行了深入研究。南京航空航天大学左洪福教授等对于航空发动机寿命预测和维修决策进行了深入的研究^[11]，其所开发的 ECC 软件也已投入到工程使用当中。夏飞、黄金泉^[12]等人利用图形模块化技术开发了某型双轴涡扇发动机的通用部件级模型仿真系统，为发动机控制系统和故障诊断研究建立了一种灵活的仿真平台。

总的来说，航空发动机状态监视和诊断技术至今还未能很好地得到应用，且无论在精度、系统可靠性等方面相对国外的还有一定的差距。国内院校及科研机构大都是在离线情况下进行对航空发动机状态监视和故障诊断的研究，这些研究，往往只针对发动机的单个系统进行故障诊断，例如只对发动机的部件的性能进行诊断，而忽略了执行机构发生故障的可能性；只针对传感器进行故障诊断，而忽略了部件发生故障的可能性。

国内有关民用航空公司和其他科研机构对航空发动机的状态监视和故障诊断也进行了一系列研究工作。其中有基于卡尔曼滤波器的发动机控制系统故障诊断；有基于小波包分析的航空发动机故障诊断；有航空发动机组态建模分析；有基于知识的故障诊断专家系统；有基于模糊神经网络的发动机故障诊断研究等^[13]。

目前，国内对 EHM 的研究刚刚起步，基本处在跟踪国外技术和概念探索的研究阶段^[14]。虽然已经意识到 EHM 的设计实现可以为我国航空领域带来的巨大益处，且对于与 EHM 相关的基本概念和研究范围等已经明确，但还没有具体的技术途径和方案得以落实。

2.2 故障诊断算法

航空发动机健康管理设计系统的算法主要包括基于模型分析的算法和基于数据驱动的算法，将这两种算法结合即为混合算法，它包含了两种算法各自的优点^[15]。

其中常用的基于模型的算法有观测器法、因果图法、参数估计法、状态估计法、等价空间法等。而常用基于数据驱动的算法有专家系统法、趋势分析法、神经网络法、统计法、相关向量机法（RVM, Relevance Vector Machine）等。

2.2.1 故障检测观测器法

故障检测观测器法^[16]的基本思想就是把系统的输出与观测器的输出相减得到残差，根据残差跟阈值相比较来判断是否出现故障，在故障观测器中建立了一个在正常工作条件下的动态系统模型，其状态的输入与真实模型的输入一样。

假设故障观测器以及控制系统如图 2-1 所示：

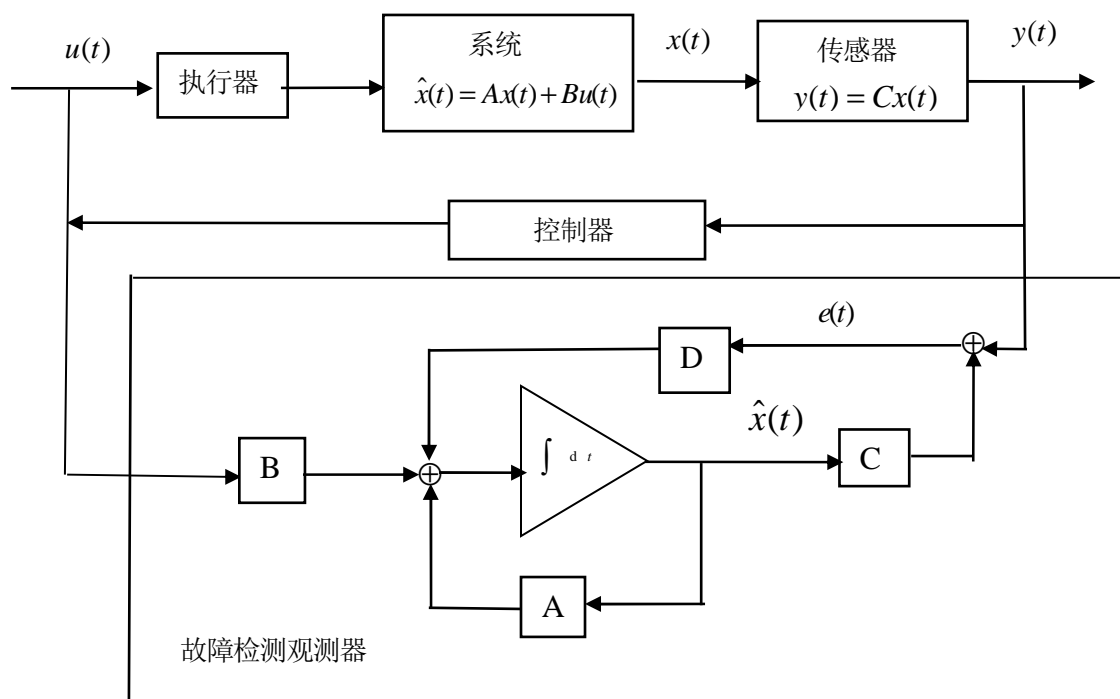


图2-1 故障检测观测器图

该系统是一个线性系统并且是可测可观的，其状态方程为：

$$\begin{aligned}\dot{x} &= Ax + Bu \\ y &= Cx\end{aligned}\quad (2-1)$$

式中 $x \in R^n$, $u \in R^P$, $y \in R^m$ 。

通过已知的模型，我们对此可以构造一个等效模型：

$$\begin{aligned}\dot{\hat{x}} &= A\hat{x} + Bu \\ \hat{y} &= C\hat{x}\end{aligned}\quad (2-2)$$

式中 $\hat{x} \in R^n$, $\hat{u} \in R^P$, $\hat{y} \in R^m$ 。

利用原模型和等效模型相比得出的输出误差，构成系统的负反馈，这样就得到了故障检测观测器。

因为对检测观测器的输入和真实系统的输入一样，故检测观测器得到的动态方程为：

$$\begin{aligned}\dot{\hat{x}} &= A\hat{x} + Bu + D(y - \hat{y}) \\ \hat{y} &= C\hat{x}\end{aligned}\quad (2-3)$$

式中，矩阵 D 为系统反馈矩阵。

状态残差为：

$$e(t) = x(t) - \hat{x}(t) \quad (2-4)$$

输出残差为：

$$\varepsilon(t) = y(t) - \hat{y}(t) \quad (2-5)$$

因此状态误差为：

$$\begin{aligned}\dot{e}(t) &= \dot{x}(t) - \dot{\hat{x}}(t) = Ax(t) + Bu(t) - A\hat{x}(t) - Bu(t) - D[y(t) - \hat{y}(t)] \\ &= (A - DC)e(t)\end{aligned}\quad (2-6)$$

输出误差方程：

$$\varepsilon(t) = y(t) - \hat{y}(t) = Ce(t) \quad (2-7)$$

当系统发生故障的时候，输出误差方程则不再是 $Ce(t)$ ，据此可以判断其故障。

2.2.2 相关向量机法

相关向量机法 RVM^[17]的回归预测模型如下所示：

(1) 模型描述

设给定训练的样本集为 $\{x_n, t_n\}_{n=1}^N$, $x_n \in R^d$, $t_n \in R$,

RVM 的模型输出为:

$$y(x; w) = \sum_{i=1}^N w_i K(x, x_i) + w_0 \quad (2-8)$$

其中 $K(x, x_i)$ 为核函数; w_i 为模型的权值; N 为样本数。

假设其目标值是独立的, 并且由带噪声的模型得来:

$$t_n = y(x_n, w) + \varepsilon_n \quad (2-9)$$

式中 ε_n 为噪声值, 服从平均值为 0, 方差为 σ^2 的高斯分布。则其所对应的训练样本集的似然函数为:

$$p(t | w, \sigma^2) = (2\pi\sigma^2)^{-N/2} \exp\left\{-\frac{1}{2\sigma^2} \|t - \phi w\|^2\right\} \quad (2-10)$$

式中 $t = [t_1 \ \cdots \ t_N]^T$; $w = [w_0 \ \cdots \ w_N]^T$; ϕ 是设计矩阵且 $\phi = [\phi(x_1), \phi(x_2), \cdots \phi(x_N)]^T$; $\phi(x_n) = [1 \ K(x_n, x_1) \ \cdots \ K(x_n, x_N)]^T$ 。

由于提高模型的泛化能力, 得到的赋予权值 w 先验的条件概率密度为:

$$p(w | \alpha) = \prod_{i=0}^N N(w_i | 0, \alpha_i^{-1}) \quad (2-11)$$

(2) 贝叶斯推理^[18]

由贝叶斯公式得, 所有未知参数的后验公式如下:

$$p(w, \alpha, \sigma^2 | t) = \frac{p(t | w, \alpha, \sigma^2) p(w, \alpha, \sigma^2)}{p(t)} \quad (2-12)$$

对于新的观测点 x_* , 相应的目标预测值 t_* , 其分布公式为:

$$p(t_* | t) = \int p(t_* | w, \alpha, \sigma^2) p(\alpha, \sigma^2 | t) d_w d_\alpha d_{\sigma^2} \quad (2-13)$$

式 (2-13) 无法直接计算, 则考虑:

$$p(w, \alpha, \sigma^2 | t) = p(w | t, \alpha, \sigma^2) p(\alpha, \sigma^2 | t) \quad (2-14)$$

则有:

$$\begin{aligned}
 p(w|t, \alpha, \sigma^2) &= \frac{p(t|w, \sigma^2)p(w|\alpha)}{p(t|\alpha, \sigma^2)} \\
 &= (2\pi)^{-(N+1)/2} |\Sigma|^{-1/2} \cdot \exp\left\{-\frac{1}{2}(w-\mu)^T \Sigma^{-1}(w-\mu)\right\}
 \end{aligned} \tag{2-15}$$

式中：后验协方差 $\Sigma = (\sigma^{-2}\phi^T\phi + A)^{-1}$ ， $A = \text{diag}(\alpha_0, \alpha_1, \dots, \alpha_N)$ ， $\mu = \sigma^{-2}\Sigma\phi^T t$ 。

需要估计超参数的最佳值来进行预测。我们在超先验的情况下，仅需对 $p(t|\alpha, \sigma^2)$ 取最大值：

$$\begin{aligned}
 p(t|\alpha, \sigma^2) &= \int p(t|w, \sigma^2)p(w|\alpha)dw \\
 &= (2\pi)^{-\frac{N}{2}} \left| \sigma^2 I + \phi A^{-1} \phi^T \right|^{-\frac{1}{2}} \cdot \exp\left(-\frac{1}{2} t^T (\sigma^2 I + \phi A^{-1} \phi^T)^{-1} t\right)
 \end{aligned} \tag{2-16}$$

(3) 超参数优化及预测

不能获取使式 (2-16) 最大的 α 与 σ^2 的解析式，为此反复使用迭代估计法得：

$$\alpha_i^{\text{new}} = \frac{\gamma_i}{\mu_i^2} \tag{2-17}$$

式中， $\gamma_i \equiv 1 - \alpha_i \Sigma_{ii}$ ， Σ_{ii} 是后验权协方差矩阵的第 i 个对角元素； μ_i 是第 i 个后验平均权值。

用同样的方法进行迭代估计，得到噪声 σ^2

$$(\sigma^2)^{\text{new}} = \frac{\|t - \phi\mu\|}{N - \sum_i \gamma_i} \tag{2-18}$$

其中 N 为样本数据的个数。

由 RVM 方法后验分布的均值给出了模型权值的估计值，并且其模型权值估计值也是权值的最大后验估计。该分布反映呈现出权值最优值的不确定性的反映，同时，它也可以表示模型预测的不确定性。

假设给定输入 x_* ，则相应输出的概率分布为：

$$p(t_*|t, \alpha_{MP}, \sigma_{MP}^2) = \int p(t_*|w, \sigma_{MP}^2)p(w|t, \alpha_{MP}, \sigma_{MP}^2)dw \tag{2-19}$$

式 (2-19) 服从正态分布，即：

$$p(t_*|t, \alpha_{MP}, \sigma_{MP}^2) = N(t_*|y_*, \sigma_*^2) \tag{2-20}$$

其中：预测均值为 $y_* = \mu^T \phi(x_*)$ ，方差为 $\sigma_*^2 = \sigma_{MP}^2 + \phi(x_*)^T \Sigma \phi(x_*)$ ，因此 RVM 新的观测值的预测输出为 $y_* = (x_*; \mu)$ 。

RVM 的回归预测模型如图2-2所示：

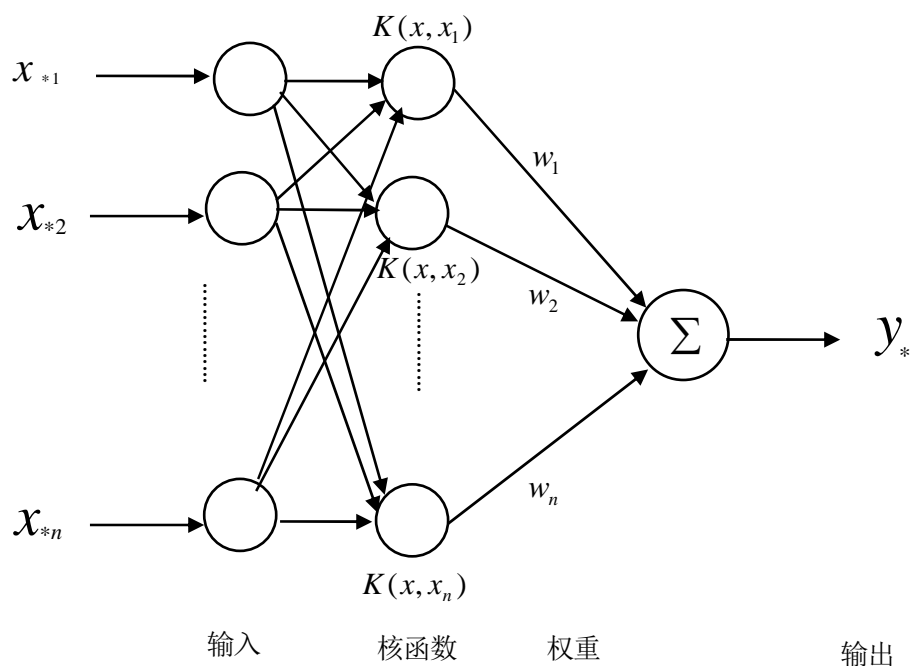


图2-2 RVM 的回归预测模型图

RVM 方法特点：

- (1) RVM 仅需确定模型输入的输出，其建模的过程相对简单；
- (2) 不需要设置模型参数，仅需对核参数进行设置；
- (3) 除了能给出预测值，也能给出预测值的方差；
- (4) 其核函数不受 Mercer 条件的限制。

2.2.3 BP 神经网络

BP 神经网络算法^[19]的基本思想为：在正向传播的过程中，输入信息经隐含层加权处理得到输出值，利用输出值与期望值比较得到的误差来进行反向传播，估计输出层的直接前导层的误差，再用这个误差逐层修改前面各层的权重系数，来逐步减小误差。




图 2-3 BP 神经网络模型图

在图 2-3 中: x_j 代表输入层第 j 个节点的输入, $j=1, \dots, M$;

θ_i 代表隐含层第 i 个节点的阈值;

w_{ij} 代表隐含层第 i 个节点到输入层第 j 个节点之间的权值;

$\phi(x)$ 代表隐含层的激励函数;

w_{ki} 代表输出层第 k 个节点到隐含层第 i 个节点之间的权值, $i=1, \dots, q$;

$\psi(x)$ 代表输出层的激励函数;

a_k 代表输出层第 k 个节点的阈值, $k=1, \dots, L$;

o_k 代表输出层第 k 个节点的输出。

(1) 信号输入的前向传播进程

隐含层第 i 个节点的输入 net_i :

$$net_i = \sum_{j=1}^M w_{ij} x_j + \theta_i \quad (2-21)$$

隐含层第 i 个节点的输出 y_i :

$$y_i = \phi(net_i) = \phi\left(\sum_{j=1}^M w_{ij} x_j + \theta_i\right) \quad (2-22)$$

输出层第 k 个节点的输入 net_k :

$$net_k = \sum_{i=1}^q w_{ki} y_i + a_k = \sum_{i=1}^q w_{ki} \phi \left(\sum_{j=1}^M w_{ij} x_j + \theta_i \right) + a_k \quad (2-23)$$

输出层第 k 个节点的输出 o_k :

$$o_k = \psi(net_k) = \psi \left(\sum_{i=1}^q w_{ki} y_i + a_k \right) = \psi \left(\sum_{i=1}^q w_{ki} \phi \left(\sum_{j=1}^M w_{ij} x_j + \theta_i \right) + a_k \right) \quad (2-24)$$

(2) 误差进行反向传播的过程

误差的反向传播, 即首先由输出层开始逐层计算各层神经元的输出误差, 然后沿原先的连接通道返回, 根据误差梯度下降法逐层调节各层的权值和阈值, 使修改后的网络的最终输出能不断修正以接近期望值。

对于每一个样本 p 的二次型误差准则函数为 E_p :

$$E_p = \frac{1}{2} \sum_{k=1}^L (T_k - o_k)^2 \quad (2-25)$$

系统对 P 个训练样本的总误差准则函数为:

$$E = \frac{1}{2} \sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p)^2 \quad (2-26)$$

根据误差梯度下降法逐步修正输出层权值的修正量 Δw_{ki} , 输出层阈值的修正量 Δa_k , 隐含层权值的修正量 Δw_{ij} , 隐含层阈值的修正量 $\Delta \theta_i$ 。

$$\Delta w_{ki} = -\eta \frac{\partial E}{\partial w_{ki}}; \quad \Delta a_k = -\eta \frac{\partial E}{\partial a_k}; \quad \Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}}; \quad \Delta \theta_i = -\eta \frac{\partial E}{\partial \theta_i} \quad (2-27)$$

输出层权值调整公式:

$$\Delta w_{ki} = -\eta \frac{\partial E}{\partial w_{ki}} = -\eta \frac{\partial E}{\partial net_k} \frac{\partial net_k}{\partial w_{ki}} = -\eta \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial net_k} \frac{\partial net_k}{\partial w_{ki}} \quad (2-28)$$

输出层阈值调整公式:

$$\Delta a_k = -\eta \frac{\partial E}{\partial a_k} = -\eta \frac{\partial E}{\partial net_k} \frac{\partial net_k}{\partial a_k} = -\eta \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial net_k} \frac{\partial net_k}{\partial a_k} \quad (2-29)$$

隐含层权值调整公式:

$$\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}} = -\eta \frac{\partial E}{\partial net_i} \frac{\partial net_i}{\partial w_{ij}} = -\eta \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial net_i} \frac{\partial net_i}{\partial w_{ij}} \quad (2-30)$$

隐含层阈值调整公式:

$$\Delta \theta_i = -\eta \frac{\partial E}{\partial \theta_i} = -\eta \frac{\partial E}{\partial net_i} \frac{\partial net_i}{\partial \theta_i} = -\eta \frac{\partial E}{\partial y_i} \frac{\partial y_i}{\partial net_i} \frac{\partial net_i}{\partial \theta_i} \quad (2-31)$$

又因为:

$$\frac{\partial E}{\partial o_k} = -\sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p) \quad (2-32)$$

$$\frac{\partial net_k}{\partial w_{ki}} = y_i, \quad \frac{\partial net_k}{\partial a_k} = 1, \quad \frac{\partial net_i}{\partial w_{ij}} = x_j, \quad \frac{\partial net_i}{\partial \theta_i} = 1 \quad (2-33)$$

$$\frac{\partial E}{\partial y_i} = -\sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p) \cdot \psi'(net_k) \cdot w_{ki} \quad (2-34)$$

$$\frac{\partial y_i}{\partial net_i} = \phi'(net_i) \quad (2-35)$$

$$\frac{\partial o_k}{\partial net_k} = \psi'(net_k) \quad (2-36)$$

(3) 最后得到以下公式:

$$\Delta w_{ki} = \eta \sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p) \cdot \psi'(net_k) \cdot y_i \quad (2-37)$$

$$\Delta a_k = \eta \sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p) \cdot \psi'(net_k) \quad (2-38)$$

$$\Delta w_{ij} = \eta \sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p) \cdot \psi'(net_k) \cdot w_{ki} \cdot \phi'(net_i) \cdot x_j \quad (2-39)$$

$$\Delta \theta_i = \eta \sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p) \cdot \psi'(net_k) \cdot w_{ki} \cdot \phi'(net_i) \quad (2-40)$$

BP 神经网络的计算流程图如图 2-4 所示:

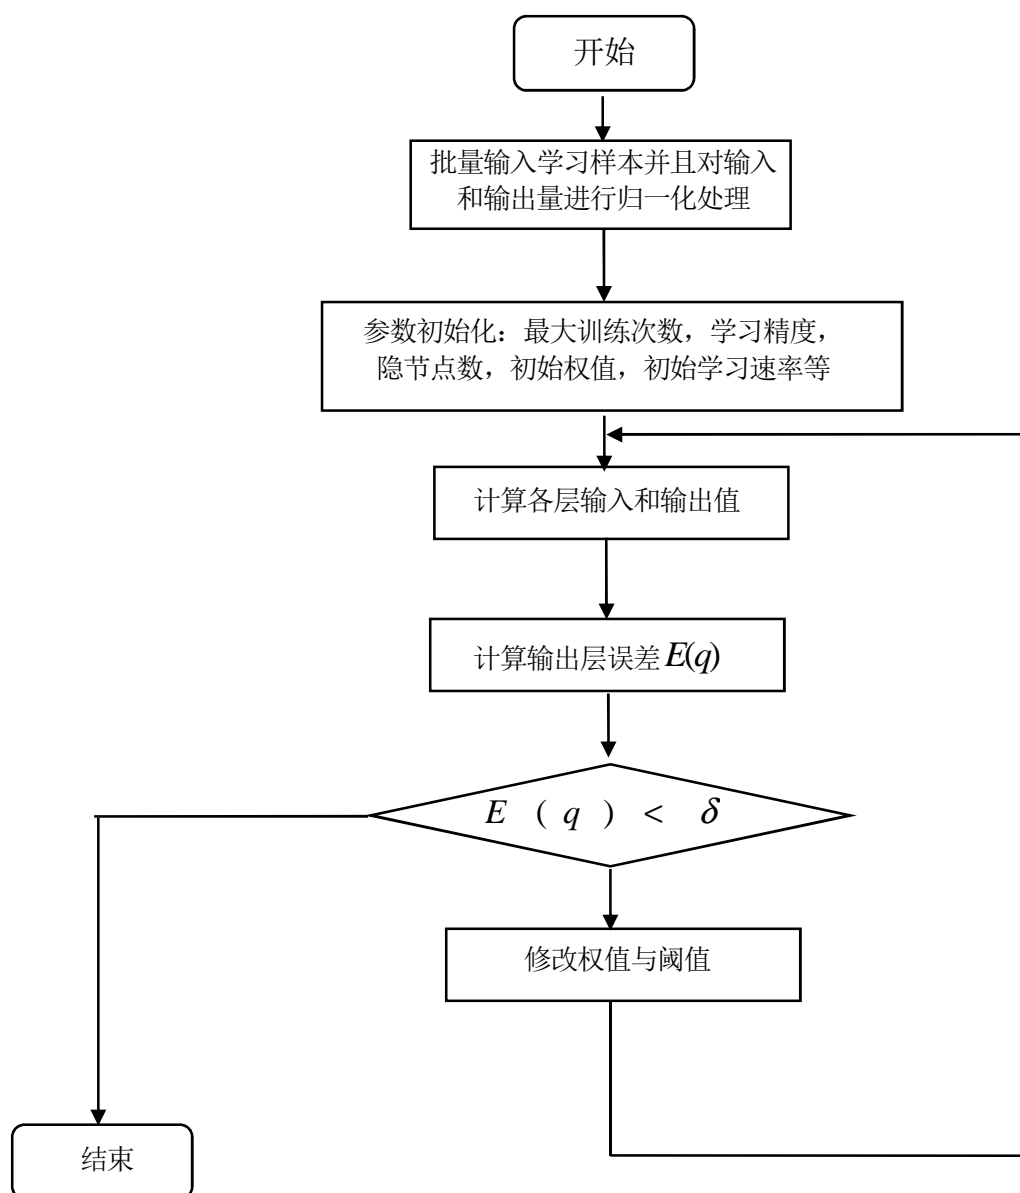


图 2-4 BP 神经网络计算流程图

2.2.4 遗传算法

遗传算法 (GA) ^[20] 是一种基于达尔文生物进化论思想的新的优化算法。GA 的基本思想是以编码空间代替问题的参数空间, 以初始编码群体为进化的基础, 评价依据为其适应度函数, 通过遗传操作建立起一个迭代过程, 实现群体中个体串的选择和遗传机

制。在这个过程中，通过一系列的选择、交叉和变异操作，最后收敛到一个最适应环境的个体上，求得问题的最优解，最终达到求解问题的目的。

从图可以看出，遗传算法的运行过程是典型的一个迭代过程，其必须完成的工作内容和基本步骤如下：

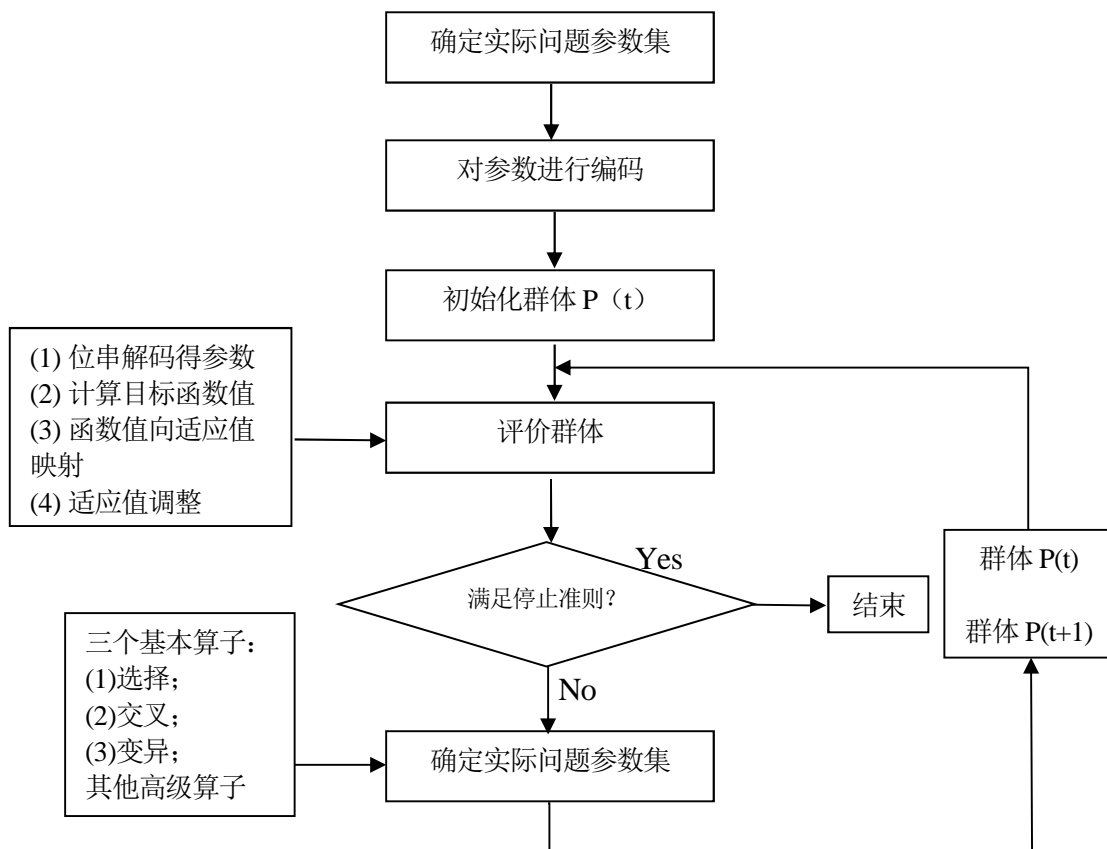


图 2-5 遗传算法流程图

(1) 选择编码的策略

根据问题的特性，编码的形式一般有：二进制编码、实数编码、大字符集编码、序列编码等多种形式。其中最基础的编码方式为二进制编码，它的应用范围及其广泛。

二进制编码把问题空间表示为基于字符集{0, 1}构成的二进制字符串的参数空间。以连续实函数的二进制编码为例，进行其编码过程的分析。

假定有一维连续的实函数 $f(x)$ ，其中 $x \in (u, v)$ ，采取长度为 L 的二进制字符串来实行定长编码，建立位串空间：

$$S^L = \{a_1, a_2, a_3, a_4, \dots, a_k\}, a_k = (a_{k1}, a_{k2}, \dots, a_{kL}), a_{kL} \in \{0, 1\}$$

$$k=1, 2, \dots, K; l=1, 2, \dots, L; K=2^L \quad (2-41)$$

其中, 个体向量为 $a_k = (a_{k1}, a_{k2}, \dots, a_{kL})$, 对应的字符串形式为

$s_k = a_{k1}a_{k2} \dots a_{kL}$ (从左到右依次表示从高位到低位), s_k 称为个体 a_k 对应的位串。

表示精度为:

$$\Delta x = (v - u) / (2^L - 1) \quad (2-42)$$

问题参数的译码函数 Γ 由位串个体从位串空间转化而来: $\{0,1\}^L \rightarrow [u, v]$ 的公式定义可以表示为:

$$x_k = \Gamma(a_{k1}a_{k2} \dots a_{kL}) = u + \frac{v-u}{2^L-1} (\sum_{j=1}^L a_{kj} 2^{L-j}) \quad (2-43)$$

对于 n 维的连续函数 $f(x)$, $x = (x_1, x_2, \dots, x_n)$, 其中 $x_i \in [u_i, v_i]$ ($i=1, 2, \dots, n$), 每一维变量的二进制编码的位串长度为 l_i , 则 x 的编码从左到右按顺序构成了总长度为 $L = \sum_{i=1}^n l_i$ 的二进制编码位串, 其相应 GA 的编码空间为: $S^L = \{a_1, a_2, \dots, a_k\}$, 其中 $K=2^L$

在此空间上的个体位串结构可以表示为:

$$a_k = (a_{k1}^1, a_{k2}^1, \dots, a_{kl_1}^1, a_{k1}^2, a_{k2}^2, \dots, a_{kl_2}^2, \dots, a_{k1}^i, a_{k2}^i, \dots, a_{kl_i}^i, \dots, a_{k1}^n, a_{k2}^n, \dots, a_{kl_n}^n) \\ s_k = a_{k1}^1 a_{k2}^1 \dots a_{kl_1}^1 a_{k1}^2 a_{k2}^2 \dots a_{kl_2}^2 \dots a_{k1}^i a_{k2}^i \dots a_{kl_i}^i \dots a_{k1}^n a_{k2}^n \dots a_{kl_n}^n, a_{kl}^i \in \{0,1\} \quad (2-44)$$

由给定的二进制的编码位串 s_k , 位段译码函数 $\Gamma^i: \{0,1\}^{l_i} \rightarrow [u_i, v_i]$ 的公式可以表示如下:

$$x_i = \Gamma^i(a_{k1}^1, a_{k2}^1, \dots, a_{kl_1}^1) = u_i + \frac{v_i-u_i}{2^{l_i}-1} (\sum_{j=1}^{l_i} a_{kj}^i 2^{l_i-j}) \quad (2-45)$$

其中个体位串 $a_{k1}^i, a_{k2}^i, a_{kl_i}^i$ 表示个体位串 s_k 的第 i 段。则整个 s_k 的译码函数表示为

$$\Gamma = \Gamma^1 \times \Gamma^2 \times \dots \times \Gamma^n。$$

(2) 遗传算法的基本操作

遗传算法有三个基本操作: 选择(Selection)、交叉(Crossover)和变异(Mutation)。

选择。选择操作是为了从当前群体中选出一定数量的质量优良的个体, 让他们可以作为父代去生成下一代的群体。这样做可以提高计算效率和全局收敛性, 避免有用遗传信息的丢失。

交叉。交叉操作在遗传算法中是最主要的操作。可以通过交叉操作生成下一代的新个体, 其新个体拥有上一代个体的特性。

变异。变异操作是在群体中选择某一个体，在选中该个体的基础上以一定概率随机改变在串结构数据中某个串的值，即以某一概率(Mutation Rate，称为变异概率)改变群体中每一个个体的某个或某些基因座上的基因值为其他的等位基因。

(3) 适应度函数

适应度函数是由目标函数确定的，作为区分群体中个体质量的标准，故又称为评价函数，既是算法的演化进程驱动，也是对于自然选择的唯一依据。

由于进化过程中对遗传操作控制的需要，选择函数变换 $T: g \rightarrow f$ ，使得对于最优解 x^* ， $\max f(x^*) = \text{opt}g(x^*)(x^* \in [u, v])$ 。

对于最小化问题，建立适应度函数 $f(x)$ 和目标函数 $g(x)$ 之间的映射关系，则有：

$$f(x) = \begin{cases} c_{\max} - g(x), & \text{若 } g(x) < c_{\max} \\ 0, & \text{否则} \end{cases} \quad (2-46)$$

其中， c_{\max} 可以是一个理论上的最大值或是输入的参数。或者是所有当前代或最近 K 代中的 $g(x)$ 的最大值，此时随着代数变化， c_{\max} 也会有变化。

对于最大化问题，一般采取以下方法：

$$f(x) = \begin{cases} g(x) - c_{\min}, & \text{若 } g(x) - c_{\min} > 0 \\ 0 & \text{否则} \end{cases} \quad (2-47)$$

其中 c_{\min} 既可以是特定的输入参数，也可以是当前所有代或最近 K 代中 $g(x)$ 的最小值。

(4) 控制参数的选择

遗传算法中的控制参数选择非常关键，控制参数的不同选取会影响到整个算法的收敛性。这些参数包括群体规模 N 、二进制（十进制）编码长度、交叉概率 p_c 、变异概率 p_m 等。

可以通过观察相对于种群最大适值 f_0 的种群平均适值 \bar{f} 的收敛性，判断 GA 是否收敛于优化点。高适值的解加快 GA 的收敛，而低适值的解防止 GA 陷入局部极小。 p_m 的值除了取决于 $f_0 - \bar{f}$ ，同时也取决于解的适值 f ；同样地， p_c 将取决于两个父代解的适值。 f 越接近于 f_0 ， p_m 则越小，甚至可以用 $f_0 - f$ 代替。同理， p_c 可以用 $f_0 - f'$ 代替，这里的 f' 是表示交叉的解中的最大适值。 p_c 和 p_m 可以表示为：

$$\begin{aligned} p_c &= k_1(f_0 - f') / (f_0 - \bar{f}) \\ p_m &= k_1(f_0 - f') / (f_0 - \bar{f}) \quad k_1, k_2 \leq 1.0 \end{aligned} \quad (2-48)$$

针对具有最大适值的解，其相应的 p_c 和 p_m 为零；种群中当前的最优解传到下一代，考虑到选择机制，可能会使种群中的解呈现指数增长同时会出现早熟。针对这个问题，在每个解的基础上引入缺省变异率，并规定这个变异率为 0.005。

下面讨论几个常数的选择，一般 p_c 和 p_m 的表达式为：

$$p_c = k_1(f_0 - f') / (f_0 - \bar{f}), \quad f' \geq \bar{f} \quad (2-49)$$

$$p_c = k_3, \quad f' > \bar{f} \quad (2-50)$$

$$p_m = k_2(f_0 - f) / (f_0 - \bar{f}), \quad f' \geq \bar{f} \quad (2-51)$$

$$p_m = k_4, \quad f' > \bar{f} \quad (2-52)$$

改进目的是为了防止算法收敛于局部的最优点。为了实现这个目的，使用适值低于平均值的解搜索包含最优解的解区域。这样的解需要完全被打破，故选择 $k_4=0.5$ 。因为具有适值 \bar{f} 的解也需要被完全打破，故选择 $k_2=0.5$ 。同理，将 k_1, k_3 的值设为 1.0，这样确保了适值小于或等于 \bar{f} 的所有解都进行了交叉操作，随着适值趋向于 f_0 ，交叉概率会减小，并且当适值等于 f_0 时，交叉概率为零。

3 研究内容、预期目标及研究方法

3.1 研究内容

- (1) 归纳总结航空发动机系统状态监控和故障诊断的现状与发展趋势
- (2) 研究航空发动机故障诊断算法，编制程序实现算法的仿真研究
- (3) 研究航空发动机系统状态参数，进行航空发动机系统故障诊断建模
- (4) 使用 Simulink 建模，构建航空发动机系统故障模拟器软件模型

3.2 预期目标

- (1) 研究先进的发动机故障诊断算法。它是实现故障诊断、故障预测和性能评估的关键技术。
- (2) 通过编制程序实现算法的仿真研究，达到提高飞机的安全性、可靠性。
- (3) 使用 Simulink 建立一套发动机故障模型。
- (4) 编写一套发动机故障诊断程序软件，实现视情维护，降低维护成本。

3.3 研究方法

3.3.1 BP-GA 结合算法

本文中主要采用基于遗传算法的 BP 神经网络算法 (简称 BP-GA)，就是在 BP 神经网络的方法基础上，将权重和阈值表示为染色体，并建立合适的适应度函数，然后进行遗传算法 (GA) 迭代，直到一定程度上的收敛。

- (1) 对权值进行编码，使之随机生成有 N 个个体量的初始群体，每个个体则表示为一个神经网络。
- (2) 对当前代中的每个个体进行解码，得到连接权值的集合，并且用该集合来构造 N 个神经网络。
- (3) 通过将每个网络的实际输出值和期望输出值进行比较，得到误差（根据某一个误差函数），其每个个体的适应度由适应度函数来进行确定。
- (4) 选择一定数量的最优个体，保留至下一代。
- (5) 使用搜索算子，如交叉、变异等对当前一代群体进行处理并生成下一代群体。
- (6) 重复以上第二步到第五步直到满足终止的条件。

- (7) 用当前群体的最优个体对 BP 网络进行初始化。
- (8) 用预设的算法参数对 BP 网络进行训练。
- (9) 算法直到满足某一条件终止。

3.3.2 故障诊断仿真建模

软件工具为 MATLAB 和 AMESim，主工作站为 PC 机。MATLAB/SIMULINK 以其强大的功能，图形可视化和易操作等特点广泛地作为许多算法数值仿真的工具。在本平台中主工作站的作用是进行故障诊断算法的设计和算法的软件数值仿真，由此建立了一种方便灵活的发动机仿真平台。

- (1) 建立 AMESim（建模软件）与 MATLAB 的连接；
- (2) 用 AMESim 软件建立飞机某一部件模型，得到仿真数据。人为设置故障，得到故障数据；
- (3) 分析 AMESim 模型的数据，用 MATLAB 得到各项指标（波形指标、峰值指标等等）；
- (4) BP-GA 研究方法训练（本文用三层神经网络）；
- (5) 用训练好后的网络确定测试数据的故障。

4 进度安排

第 1~2 周 安排任务，查阅文献，翻译外文资料；

第 3~4 周 熟悉航空发动机系统参数，写开题报告；

第 5~8 周 建立发动机故障模拟软件模型；

第 9~11 周 进行系统的调试，完成发动机故障诊断算法，完成论文初步撰写；

第 12~14 周 完成控制程序的编写；

第 15 周 论文整理；

第 16 周 答辩准备，答辩。

本人签名：

年 月 日

参考文献

- [1] 张绍基. 航空发动机控制系统的研发与展望[J], 航空动力学报, 2004, 19(3):375-382.
- [2] 方前. 航空发动机系统建模与故障诊断研究[D], 西安:西北工业大学, 2005.
- [3] 刘大响, 彭友梅. 新概念航空发动机展望[J], 现代军事, 2003(11).
- [4] O Benedettini, T S Baines, H W Lightfoot, et al. State-of -the-art in integrated vehicle health management [J]. Proceedings of the Institution of Mechanical Engineers, 2009, 223(2): 157-170
- [5] 陈予恕, 张华彪. 航空发动机整机动力学研究进展与展望[J]. 航空学报, 2011, 32(8):1371-1391.
- [6] 郝英, 孙健国, 白杰. 航空燃气涡轮发动机气路故障诊断现状与展望[J], 航空动力学报, 2003, 18(6):753-760.
- [7] Swan. J. A. Analytical Redundancy Design for Improved Engine Control Reliability Final Review[R]. AIAA-88-3776.
- [8] 方昌德. 发动机状态监视和故障诊断系统的发展[J], 国际航空, 2005, 6:66-68.
- [9] Sanjay G. Controls and health management technologies for intelligent aerospace propulsion systems[R]. AIAA-2004-0949.
- [10] King S, Bannister P R, Clifton D A, et al. Probabilistic approach to the condition monitoring of aerospace engines[J]. Proceedings of the Institution of Mechanical Engineers, Part G: Journal of Aerospace Engineering, 2009, 223(5):533-541.
- [11] 任淑红, 左洪福. 基于性能衰退的航空发动机剩余寿命组合预测方法[J], 机械科学与技术, 2011, 30(1):23-29.
- [12] 夏飞, 黄金泉, 周文祥. 基于 MATLAB/SIMULINK 的航空发动机建模与仿真研究[J], 2007, 22(12):2134-2138
- [13] 孙晓倩, 艾延廷, 张振. 航空发动机传感器故障诊断方法研究[J], 沈阳航空工业学院学报, 2010, 27(2):15-19.
- [14] 王施, 王荣桥, 陈志英. 航空发动机健康管理综述[J], 燃气涡轮试验与研究, 2009, 22(1):51-58.

- [15] 费成巍, 艾延廷. 航空发动机健康管理系统设计技术[J], 航空发动机, 2009, 35(5):24-29.
- [16] 吴彬. 基于模型的故障诊断技术及其在电动舵机上的应用[D], 湘潭:湘潭大学, 2008
- [17] Tipping, M. E. The relevance vector machine[A].Proc.of the Uncertainty in Artificial Intelligence Process-ings[C]. 2000:46-53.
- [18] S Ferreiro, A Arnaiz, B Sierra, I Irigoien. A Bayesian network model integrated in a prognostics and health management system for aircraft line maintenance[J]. Journal of Aerospace Engineering, 2011, 225(8): 886~901
- [19] 袁新科. 基于 BP 神经网络的发动机故障诊断研究[D]. [硕士学位论文], 济南:山东大学, 2006
- [20] 何光宇, 刘新学, 尉询楷. 遗传算法在航空发动机故障诊断中的应用[J]. 火力与指挥控制, 2006, 31(11):82-84.

指导教师意见

指导教师签字:

年 月 日